

프롬프트에 곁들인 신호는 AI의 답을 바꾸는가?

ChatGPT·Gemini·Claude 세 AI에 대한 반복 실험

유지원

2026-10-06

0. 초록

AI의 답은 놀랍도록 똑똑해 보이지만, 그 답이 질문의 내용 때문에 나오는지 프롬프트에 곁들인 말투와 구조 때문에 나오는지 따로 확인해야 한다. 이 연구는 "AI의 답변은 질문 내용 자체보다, 프롬프트에 곁들여지는 사회적·구조적 신호(예시 제시, 다수의견 프레이밍, 역할 부여, 토론 구조)에 따라 학습된 언어 패턴을 재현하며 체계적으로 달라진다"는 가설을 네 개의 하위 실험(H1~H4)으로 나누어, ChatGPT·Gemini·Claude에 같은 횟수로 직접 묻고 원자료를 모아 확인했다. 이미지 생성(H1)은 모델·조건당 5장, 텍스트 실험(H2~H4)은 모델·조건당 10회를 모았다. 결과, (H1) 세 AI 모두 구체적 설명을 줄 때 포스터의 색 다양성이 낮았고(ChatGPT 0.113 대 0.448, Gemini 0.250 대 0.421, Claude 0.527 대 0.587), 효과 크기는 모델마다 달랐다. (H2) 개인 의견 대신 다수 의견을 물으면 ChatGPT는 반대로 쏠렸지만($p=0.087$) Claude는 전혀 달라지지 않았고, AI 간 기본 입장 차이가 프레이밍 효과보다 컸다. (H3) 한 줄짜리 전문가 페르소나는 정답률도 응답 스타일도 일관되게 바꾸지 못했다. (H4) 자기 토론은 정답률을 바꾸지 못했지만(세 AI 모두 S와 D 동일) 응답을 약 3~5배 길게 만들고 검증 표현을 늘렸다. 정답률이 거의 만점인 천장효과, 계정·표본 한계, 토론 프롬프트가 반박을 요구했다는 점 때문에 가설이 전체적으로 지지되었다고 말할 수는 없다. 신호가 답의 "형식과 분량"을 바꾸는 정도는 분명했고, "정답과 입장"을 바꾸는 정도는 AI와 과제에 따라 달랐다.

키워드: 프롬프트 엔지니어링, 대규모 언어모델, 반복 실험, 페르소나, 자기 토론, 다수의견 프레이밍

1. 서론

1-1. 문제의식

AI는 말도 안 되게 똑똑할까! 수학 문제를 풀고, 포스터를 그리고, 도덕적 딜레마에 의견까지 낸다. 그런데 같은 AI에게 "당신은 20년 경력의 전문가입니다"라고 한 줄을 덧붙이면 정말 더 똑똑해질까? 두 명의 전문가가 토론하는 척하게 하면 정답에 더 가까워질까? 포스터를 구체적으로 설명해 주면 결과가 더 다양해질까, 오히려 한 가지 틀에 갇힐까? 나는 동아리 포스터를 AI로 만들 때 첫 시안이 항상 비슷한 느낌이었다는 경험에서 이 질문을 시작했다.