

1-2. 가설

AI에게 감정이나 의도가 있어서 반응이 달라지는 것이 아니라는 전제를 먼저 세웠다. 이 전제는 연구 설계 단계에서 내가 직접 제기했고(압박 문구 실험을 기각한 이유이기도 하다, [과정기록/01_가설설정.md](#)), 사람의 글쓰기 패턴을 학습한 모델이 비슷한 신호가 들어오면 비슷한 패턴을 재현한다는 뜻이다. 이를 한 문장으로 쓰면 다음과 같다.

AI의 답변은 질문 내용 자체보다, 프롬프트에 곁들여지는 사회적·구조적 신호(예시 제시, 다수의견 프레이밍, 역할 부여, 토론 구조)에 따라 학습된 언어 패턴을 재현하며 체계적으로 달라진다.

무엇이(독립변수) 무엇에(종속변수) 영향을 주는지는 아래 표와 같다. 각 하위 가설은 반증 조건을 실험 전에 정했다. 표에 나오는 "색 다양성"과 정답률·응답 지표의 정확한 정의와 수식은 2-2절, 2-4절에, 검정 방법은 2-6절에 있다.

표 1. 하위 실험의 신호, 측정, 반증 조건

하위 실험	바꾸는 신호	보는 결과	틀렸다면 나올 결과(반증 조건)
H1 예시	포스터 요청에 구체적 설명을 넣음/안 넣음	같은 조건 포스터 5장끼리의 색 다양성	설명을 넣어도 다양성이 같거나 오히려 높음
H2 다수의견	"당신의 생각은?" 대 "대부분의 사람들은?"	찬성/반대/유보 분포	두 프레이밍의 분포가 거의 같음(차이 1~2건 이내)
H3 페르소나	"20년 경력의 전문가" 한 줄을 추가	정답률(과 응답 스타일)	정답률이 같거나 더 낮음 (문제별 차이 1건 이내)
H4 자기 토론	두 전문가의 토론 형식 지시	정답률(과 응답 스타일)	정답률이 같거나 더 낮음

1-3. 선행 연구: 이미 알려진 것과 이 연구가 새로 보는 것

이미 알려진 것. 프롬프트에 예시를 주는 few-shot 방식은 대규모 언어모델이 과제를 수행하는 기본 방법이 되었다(Brown et al., 2020). 풀이 과정을 쓰게 하는 chain-of-thought도 추론을 개선한다고 보고되었다(Wei et al., 2022). 반대로 프롬프트 형식의 사소한 차이가 결과를 크게 바꾼다는 보고도 있다(Sclar et al., 2024). AI는 사용자의 견해에 맞추는 경향(아첨)이 있고(Sharma et al., 2024), 다수의견에 동조하며 특히 불확실할수록 더 그렇다(Zhu et al., 2025; Weng et al., 2025). 시스템 프롬프트에 페르소나를 넣어도 정확도는 일관되게 오르지 않는다(Zheng et al., 2024). 여러 인스턴스가 토론하면 추론과 사실성이 좋아졌다는 보고(Du et al., 2024)와, 외부 피드백 없이 스스로 고치기는 잘 안 된다는 보고(Huang et al., 2024)가 함께 있다. 창작에서는 AI의 도움을 받은 글이 서로 더 비슷해진다는 사람 대상 실험이 있다(Doshi & Hauser, 2024). 구조화된 프롬프트 형식이 출력 다양성을 줄인다는 프리프린트도 있고(Yun et al., 2025), 출력이 비슷해지는 정도가 과제에 따라 다르다는 제목의 프리프린트도 있다(Jain et al., 2025; 제목과 저자만 확인했다).