

#	문제	정답
Q15	100! 끝에 연속으로 붙는 0의 개수	24

표 6. H3·H4 조건별 프롬프트

조건	프롬프트
C 통제 / S 혼자 풀기	문제 + 공통 지시문("풀이 과정은 자유롭게 쓰되 도구는 쓰지 말고 직접 풀고, 마지막 줄에 정답: <값> 형식으로 적을 것")
P 페르소나	문제 앞에 "당신은 이 분야에서 20년 경력을 가진 최고 수준의 전문가입니다." 한 줄 추가
D 자기 토론	문제 앞에 "두 명의 전문가 A와 B가 토론하는 형식으로 푸세요. A가 먼저 풀이와 답을 제시하고, B는 오류나 허점을 구체적으로 찾아 반박하며, A가 응답하는 식으로 2라운드 토론한 뒤 합의한 최종 답을 내세요."를 추가

- S(혼자 풀기)는 C와 프롬프트가 같아서 C의 응답 10개를 H4에서 그대로 재사용했다. 따라서 H3과 H4의 비교는 서로 독립이 아니다.

정답률의 정의. 응답의 마지막 줄 정답: <값> 에서 값을 읽고, 실패·공백·%와 끝의 마침표를 지운 문자열이 정답표의 값과 같으면 정답(1), 아니면 오답(0)이다. 마지막 줄이 이 형식이 아니면 오답이 아니라 "형식오류"로 따로 센다(이번에는 없었다).

$$\text{정답률} = (\sum_{q=1}^{10} \text{정답}_q) / 10 \quad (6)$$

응답 내용 지표의 정의. 정답률이 거의 만점이라는 것을 일부 데이터를 본 뒤 알았기 때문에 추가했다 (표 7). 저장한 응답 파일에서 맨 첫 줄의 설명([모델·조건·시각·URL])을 뺀 본문을 r이라 할 때, 지표는 다음과 같이 규칙으로 자동 계산한 값이다.

- chars(r): 본문의 글자 수(공백·줄바꿈 포함)
- eq(r): 문자 "="의 개수(풀이 단계 수의 대리 지표)
- verify(r): 정규식 `검산|검증|재확인|다시 확인|확인해|확인하|재계산|다시 계산|교차|mod ?\d|mod\)|합동식으로 확인|double.?check|verify` 에 일치한 횟수
- persona(r): 정규식 `전문가로서|경력|20년|전문가의 입장|제 경험` 에 일치한 횟수(페르소나 자기언급)
- rebut(r): 정규식 `오류|허점|틀렸|틀린|실수|잘못|반박|지적` 에 일치한 횟수

같은 문제 q에서 조건을 비교한 차이를 δ_q , 문제 10개의 평균을 Δ 라 한다. H3은 페르소나와 통제의 차이, H4는 토론과 통제(혼자 풀기)의 차이이다.

$$\delta_q = m(r_{\text{비교 조건}, q}) - m(r_{C, q}), \Delta = (1 / 10) \cdot \sum_q \delta_q \quad (m \text{은 위 지표 중 하나}) \quad (7)$$

단어 목록은 내가 정했으므로 목록을 바꾸면 값이 달라진다. 특히 verify의 mod 항은 나머지를 구하는 문제(Q2, Q12)에서 풀이 자체가 "mod"라는 단어를 쓰기 때문에 모든 조건에서 값이 커진다. 같은 문제끼리 빼는 방식이라 대부분 상쇄되지만, 응답이 긴 토론 조건에서는 이 단어가 더 자주 나와 차이가