

다르게 나온 부분. Claude는 두 프레임이 완전히 같았다(반증 조건에 해당). 또 같은 문장에 대한 기본 입장이 모델마다 크게 달랐다(X에서 Gemini 찬성 10, Claude 반대 10). 프레이밍 효과보다 모델 간 차이가 훨씬 컸다. 어느 모델의 p값도 0.05 아래가 아니다.

다르게 나온 이유로 검토한 것. (1) Y의 "반대"는 AI가 입장을 바꾼 것이 아니라 "다수가 반대할 것"이라고 정확히 추정한 것일 수 있다. ChatGPT의 Y 응답은 대체로 "대부분의 사람들은 반대하거나 거부감을 느낄 가능성이 높다"는 취지였고 트롤리 문제 연구의 일반적 경향을 설명했다. (2) Gemini의 X·Y는 서로 다른 계정에서 실행됐다.

3-4. H3·H4: 정답률은 거의 천장이었고 차이는 응답 내용에서 나왔다




그림 6. H3·H4 응답 길이와 정답률

표 14. H3·H4 정답률과 응답 길이

모델	S/C 정답	P 정답	D 정답	길이 S→P→D (글자 수 평균)
Claude	10/10	10/10	10/10	274 → 300 → 1,483
Gemini	10/10	10/10	10/10	433 → 441 → 1,865
ChatGPT	9/10	8/10	9/10	211 → 250 → 714

표 15. H3·H4 검증·반박 표현의 평균

모델	검증 표현 평균 S→P→D	반박 표현 평균 S→P→D
Claude	1.0 → 0.9 → 7.1	0.0 → 0.0 → 3.9
Gemini	1.6 → 1.8 → 9.3	0.0 → 0.0 → 5.1
ChatGPT	0.6 → 1.4 → 4.0	0.0 → 0.0 → 0.9

문제별 정답 여부(O 정답, X 오답)와 응답 길이(글자 수)는 다음과 같다.