

모델	지표	C(=S)	P	D	P-C (p)	D-C (p)
Gemini	페르소나 자기언급	0.0	0.0	0.0	+0.0 (1.000)	+0.0 (1.000)
Gemini	반박 표현	0.0	0.0	5.1	+0.0 (1.000)	+5.1 (0.003)
Claude	글자 수	273.6	300.2	1483.0	+26.6 (0.072)	+1209.4 (0.003)
Claude	등호 수(풀이 단계)	5.9	8.1	20.2	+2.2 (0.351)	+14.3 (0.003)
Claude	검증 표현	1.0	0.9	7.1	-0.1 (1.000)	+6.1 (0.003)
Claude	페르소나 자기언급	0.0	0.0	0.0	+0.0 (1.000)	+0.0 (1.000)
Claude	반박 표현	0.0	0.0	3.9	+0.0 (1.000)	+3.9 (0.003)

H3 페르소나. 정답률은 Claude-Gemini가 두 조건 모두 만점이라 차이를 볼 수 없었다. ChatGPT는 통제 9/10, 페르소나 8/10이다. 이 한 건 차이를 만든 문제는 Q5인데, ChatGPT가 틀린 문제는 Q5(페르소나만)와 Q13(통제·페르소나·토론 세 조건 모두)뿐이다. 페르소나 때문에 틀렸다고 읽기 어렵다. 응답 길이는 ChatGPT에서만 약간 늘었다(+39.5자, $p=0.007$)가, 지표를 여러 개 본 가운데 하나다. 페르소나 자기언급("전문가로서" 등)은 세 모델 모두 30건 중 0건이었다. 반증 조건(정답률 차이 없음)에 해당해 가설은 지지되지 않았다.

H4 자기 토론. 정답률은 세 모델 모두 S와 D가 같았다(Claude 10/10 대 10/10, Gemini 10/10 대 10/10, ChatGPT 9/10 대 9/10). 반증 조건에 해당한다. 반면 응답 내용은 크게 달랐다. 세 모델 모두 토론 형식에서 응답이 약 3~5배 길어지고 검증·반박 표현이 늘었다(순열검정 p 는 Claude-Gemini 길이·검증·반박 모두 0.003, ChatGPT는 길이 0.003, 검증 0.004, 반박 0.031).

원자료에서 확인한 토론 사례.

- Gemini Q11(9876×6789): 전문가 A가 처음부터 정답 67,048,164를 냈는데 B가 11의 배수 판정을 잘못 적용해 "오류 발견"이라고 주장했고, A는 중간에 틀린 값 67,058,164를 냈다가 마지막에 검증을 다시 해 원래 정답으로 돌아왔다.
- Gemini Q14: B가 "치명적인 산술 오류"라고 지적했지만 계산해 보니 A가 맞았고, B가 곧 정정했다.
- Gemini Q13, Q15: A가 처음에 틀린 값(10, 20)을 냈고 B가 바로잡았다.
- ChatGPT Q13: B가 "빠진 p 는 없다"고 검증했지만 A와 같은 오류(peppers의 p 를 2개로 셈)를 유지해 두 전문가가 틀린 답 8에 합의했다.
- Claude: B는 "계산 실수가 날 수 있다"처럼 실수의 가능성을 짚고 독립 검산을 요구하는 형태였고, 존재하지 않는 오류를 확정적으로 주장한 사례는 읽은 범위에서 없었다.

4. 논의

4-1. 가설은 지지되었는가

하위 실험별 판정은 다음과 같다.