

표 19. 하위 실험별 판정

하위 실험	판정	근거
H1 예시	방향은 지지(효과 크기는 모델별로 다름)	3모델 모두 $A < B$. 표본 5장, 통계 검정 안 함
H2 다수의견	일부만 지지, 확정 불가	ChatGPT·Gemini에서 방향이 맞고 Claude에서는 기각. 모든 $p > 0.05$
H3 페르소나	지지되지 않음	정답률 같음, 자기언급 0건. 쉬운 문제라는 한계
H4 토론 (정확도)	지지되지 않음	정답률 S와 D 동일
H4 토론(응답 내용)	분명히 달라짐, 단 해석에 한계	길이 3~5배, 검증·반박 표현 증가. 프롬프트가 반박을 요구함

종합하면 "신호에 따라 답변이 체계적으로 달라진다"는 가설은, **형식과 분량**에서는 뚜렷했고(H1 색 다양성, H4 응답 길이), **정답과 입장**에서는 AI와 과제에 따라 달랐다(H2는 모델별 상이, H3·H4는 정답률 동일). 가설 전체가 지지되었다고 말할 수 없다.

4-2. 가설을 고친 과정

표 20. 가설의 수정 전과 후

	문장
처음(수정 전)	AI의 답변은 질문 내용 자체보다, 프롬프트에 곁들여지는 사회적·구조적 신호에 따라 학습된 언어 패턴을 재현하며 체계적으로 달라진다. (정답·입장·다양성 모두에 해당하는 것으로 읽힌다)
데이터를 본 뒤(수정 후)	프롬프트에 곁들여진 신호는 AI의 답의 형식과 분량 (색 구성, 응답 길이, 검증 표현)은 분명히 바꾸지만, 정답과 입장 을 바꾸는 정도는 AI와 과제에 따라 다르며, 이번 쉬운 문제에서는 정답을 바꾸지 못했다.

수정 후 문장은 결과를 본 뒤에 쓴 것이므로 새로운 증거가 아니라 다음 실험에서 검증해야 할 가설이다. 어려운 문제 세트, 길이를 맞춘 통제 조건(예: 토론 형식 없이 같은 분량으로 풀기), 반복 시행이 필요하다.

4-3. 이 연구로 말할 수 없는 것 (한계)

- 1. 천장효과.** H3·H4의 정답률이 거의 만점이라 신호가 정확도를 바꾸는지 검증하지 못했다. "차이 없음"이 곧 "효과 없음"의 증명은 아니다.
- 2. 표본.** H1은 모델·조건당 5장, H2~H4는 모델·조건당 10회이고 문제당 1회다. 같은 문제를 반복해 응답의 흔들림을 재지 못했다. p값은 시행이 독립이 아니고 표본이 작아 확증용이 아니다.
- 3. 적응적 확장.** 표본 확대와 문제 추가는 일부 결과를 본 뒤에 이뤄졌다. 새 문제를 어렵게 고르지는 않았고 기존 자료를 버리지도 않았지만, 사전 등록된 실험은 아니다.