

4. **계정·환경.** ChatGPT는 같은 계정에서 연속 대화했고 웹 서비스의 맥락·메모리를 통제하지 못했다. Gemini H2는 프레임과 계정이 섞였다. 웹 모델의 시스템 프롬프트와 정확한 버전도 통제·기록하지 못했다. 다른 사람 소유 계정에서 받은 일부 자료는 제외했지만, 그 계정에 생성한 대화가 남아 있다.
5. **프롬프트가 요구한 행동.** 토론 프롬프트는 반박을 하라고 지시했으므로 길이·반박 표현의 증가를 AI가 스스로 신중해진 것으로 읽으면 안 된다. 한 모델이 두 역할을 연기하는 방식은 서로 다른 모델 인스턴스를 쓴 Du et al.(2024)의 설계와 다르다.
6. **측정.** H1의 색 다양성은 레이아웃·구도의 다양성을 직접 재지 못하고, Claude는 코드 색상값의 근사다. 응답 지표는 정규식이라 단어 목록에 따라 값이 달라진다. H2의 Y 응답은 입장 변경인지 다수 의견 추정인지 구분하지 못했다.
7. **주제 일반화.** 포스터 한 주제, 딜레마 하나, 계산·세기 문제 10개로만 실험했다.
8. **선행 연구와의 비교.** 선행 연구는 초록 수준에서만 확인했다. 우리 결과가 그 연구들을 재현하거나 반박한다고 말하지 않고, 방향이 모순되지 않는다고만 쓴다.

4-4. 선행 연구와의 관계

H3의 "정답률 차이 없음"은 페르소나가 정확도를 일관되게 높이지 않는다는 Zheng et al.(2024, 최종본)과 방향이 모순되지 않는다. 같은 논문의 첫 버전(2023)은 "역할을 주면 성능이 오른다"였다가 최종본에서 결론이 바뀌었다. H4의 ChatGPT Q13에서 두 전문가가 같은 오류에 합의한 사례는, 외부 피드백 없이 스스로 고치기가 어렵다는 Huang et al.(2024)의 보고와 같은 방향이다. 다만 한 사례이며 일반화하지 않는다. H1의 방향은 AI를 쓴 결과물이 서로 비슷해진다는 Doshi & Hauser(2024)의 사람 대상 실험과 관련되지만 대상과 측정이 달라 직접 비교할 수 없다.

4-5. 결론

네 가지 신호(구체적 설명, 다수 의견, 전문가 한 줄, 토론 형식)를 세 AI에 같은 횟수로 넣어 본 결과, AI의 답은 신호에 따라 **어떻게 쓰이는가**(색 구성, 길이, 검증 표현)는 분명히 달라졌지만 **무엇이 정답이고 어떤 입장인가**는 대체로 달라지지 않았거나 AI마다 달랐다. 구체적 설명은 포스터를 한 틀로 모았고, 토론은 응답을 3~5배 길게 만들었으며, 전문가 한 줄은 정답도 스타일도 거의 바꾸지 못했다. 다수 의견을 물었을 때는 ChatGPT만 반대로 쓸렸고, 이 차이는 입장 변경인지 다수 의견 추정인지 이 설계로는 구분되지 않는다. 데이터의 한계 때문에 이 결과로 "AI는 신호를 따라 학습된 패턴을 재현할 뿐"이라고 단정할 수는 없지만, 적어도 "AI의 답은 같은 질문이라도 곁들인 말에 따라 모양이 달라진다"는 점은 세 AI 모두에서 확인되었다.

AI는 말도 안 되게 똑똑한가? 이번 실험에서 세 AI는 계산 도구 없이 푸는 산술 문제 10개를 거의 다 맞혔고, 틀린 것은 ChatGPT의 문자 세기 문제(Q13 세 조건, Q5 페르소나 조건 1건)뿐이었다. 그러니 똑똑하다는 인상은 틀리지 않다. 그러나 똑똑해 보이는 답의 겉모양은 한 줄의 말에 따라 쉽게 바뀌었고, 두 전문가가 서로 검증했다고 해서 둘 다 틀린 답에서 벗어나지는 못했다.

그럼에도 나는 AI가 정말 기하급수적으로 발달하고 있는 것 같다. 이것은 이번 데이터로 검증한 결과가 아니라 저자인 내 의견이다. 이 연구는 단 며칠, 세 서비스의 한 시점만 보았기 때문에 발전 속도를 측정할 수 없다. 다만 내가 인용한 논문 중 Zheng et al.은 2023년 11월 첫 버전과 2024년 10월