

- ChatGPT Q13: B가 "빠진 p는 없다"고 검증했지만 A와 같은 오류(peppers의 p를 2개로 셈)를 유지해 두 전문가가 틀린 답 8에 합의했다.
- Claude: B는 "계산 실수가 날 수 있다"처럼 실수의 가능성을 짚고 독립 검산을 요구하는 형태였고, 존재하지 않는 오류를 확정적으로 주장한 사례는 읽은 범위에서 없었다.

4. 논의

4-1. 가설은 지지되었는가

하위 실험별 판정은 다음과 같다.

표 19. 하위 실험별 판정

하위 실험	판정	근거
H1 예시	방향은 지지(효과 크기는 모델별로 다름)	3모델 모두 $A < B$. 표본 5장, 통계 검정 안 함
H2 다수의견	일부만 지지, 확정 불가	ChatGPT-Gemini에서 방향이 맞고 Claude에서는 기각. 모든 $p > 0.05$
H3 페르소나	지지되지 않음	정답률 같음, 자기언급 0건. 쉬운 문제라는 한계
H4 토론 (정확도)	지지되지 않음	정답률 S와 D 동일
H4 토론(응답 내용)	분명히 달라짐, 단 해석에 한계	길이 3~5배, 검증·반박 표현 증가. 프롬프트가 반박을 요구함

종합하면 "신호에 따라 답변이 체계적으로 달라진다"는 가설은, **형식과 분량**에서는 뚜렷했고(H1 색 다양성, H4 응답 길이), **정답과 입장**에서는 AI와 과제에 따라 달랐다(H2는 모델별 상이, H3·H4는 정답률 동일). 가설 전체가 지지되었다고 말할 수 없다.

4-2. 가설을 고친 과정

표 20. 가설의 수정 전과 후

	문장
처음(수정 전)	AI의 답변은 질문 내용 자체보다, 프롬프트에 곁들여지는 사회적·구조적 신호에 따라 학습된 언어 패턴을 재현하며 체계적으로 달라진다. (정답·입장·다양성 모두에 해당하는 것으로 읽힌다)
데이터를 본 뒤(수정 후)	프롬프트에 곁들여진 신호는 AI의 답의 형식과 분량 (색 구성, 응답 길이, 검증 표현)은 분명히 바꾸지만, 정답과 입장 을 바꾸는 정도는 AI와 과제에 따라 다르며, 이번 쉬운 문제에서는 정답을 바꾸지 못했다.