

다수 의견을 물었을 때는 ChatGPT만 반대로 쓸렸고, 이 차이는 입장 변경인지 다수 의견 추정인지 이 설계로는 구분되지 않는다. 데이터의 한계 때문에 이 결과로 "AI는 신호를 따라 학습된 패턴을 재현할 뿐"이라고 단정할 수는 없지만, 적어도 "AI의 답은 같은 질문이라도 결들인 말에 따라 모양이 달라진다"는 점은 세 AI 모두에서 확인되었다.

AI는 말도 안 되게 똑똑한가? 이번 실험에서 세 AI는 계산 도구 없이 푸는 산술 문제 10개를 거의 다 맞혔고, 틀린 것은 ChatGPT의 문자 세기 문제(Q13 세 조건, Q5 페르소나 조건 1건)뿐이었다. 그러니 똑똑하다는 인상은 틀리지 않다. 그러나 똑똑해 보이는 답의 겉모양은 한 줄의 말에 따라 쉽게 바뀌었고, 두 전문가가 서로 검증했다고 해서 둘 다 틀린 답에서 벗어나지는 못했다.

그럼에도 나는 AI가 정말 기하급수적으로 발달하고 있는 것 같다. 이것은 이번 데이터로 검증한 결과가 아니라 저자인 내 의견이다. 이 연구는 단 며칠, 세 서비스의 한 시점만 보았기 때문에 발전 속도를 측정할 수 없다. 다만 내가 인용한 논문 중 Zheng et al.은 2023년 11월 첫 버전과 2024년 10월 최종본에서 결론이 정반대로 바뀌었다. 약 1년 사이에도 이 분야의 "알려진 사실"이 이렇게 빨리 뒤집힌다면, 오늘 이 논문의 결과도 곧 낡은 것이 될 것이다. 그래서 이 실험의 설계, 원자료, 스크립트를 모두 남겼다. 다음에 같은 질문을 다시 묻고 비교해 볼 수 있도록.

5. 부록

5-1. 재현 방법

폴더 구성(ZIP을 푼 폴더 기준):

```

README.md                패키지 안내
AI와_나의_판단_3줄.md
논문/논문.md, 논문.pdf   이 논문 (그림은 논문/그림/, PDF는 논문/빌드.py로 만든다)
과정기록/                가설 설정(1단계), 문헌 조사(2단계) 기록
실험/01_예시효과/        H1 설계, 원자료(raw_data), 분석.py, 포스터모음.py, 결과해석.md
실험/02_다수의견프레이밍/ H2 설계, 원자료, 집계.py, 결과해석.md
실험/03_페르소나부여/    H3 설계, 원자료, 결과해석.md
실험/04_혼자풀기vs자기토론/ H4 설계, 원자료, 결과해석.md
실험/채점.py, 지표분석.py, 그래프.py, 표생성.py   H3·H4 채점, 응답 내용 지표, 그래프, 수치 표
실험/제외_타인계정ChatGPT/ 분석에서 뺀 자료(삭제하지 않고 보관)
  
```

다시 계산하는 순서(Python 3, matplotlib, Pillow, numpy 가 필요하다).

```

cd 실험
python 01_예시효과/분석.py      # H1 다양성 점수 (분석결과.txt 출력과 같아야 한다)
python 02_다수의견프레이밍/집계.py # H2 입장 분포 + Fisher
python 채점.py                  # H3·H4 자동 채점 -> H3H4_채점결과.txt
python 지표분석.py              # H3·H4 응답 내용 지표 -> 지표분석결과.txt
python 그래프.py                # H2, H3·H4 그림
python 표생성.py                # 논문의 수치 표 -> 논문/수치표.md
  
```