

8. Sharma, M., Tong, M., Korbak, T., Duvenaud, D., Aspell, A., Bowman, S. R., et al. (2024). Towards understanding sycophancy in language models. *The Twelfth International Conference on Learning Representations (ICLR 2024)*. <https://arxiv.org/abs/2310.13548> (실험) → AI가 사용자의 견해에 맞추는 경향(H2).
9. Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., et al. (2022). Chain-of-thought prompting elicits reasoning in large language models. *Advances in Neural Information Processing Systems*, 35. <https://arxiv.org/abs/2201.11903> (실험) → 풀이 과정을 쓰게 하는 구조적 신호가 추론을 바꾼다는 보고(H3·H4의 풀이 지시).
10. Weng, Z., Chen, G., & Wang, W. (2025). Do as we do, not as you think: The conformity of large language models. *The Thirteenth International Conference on Learning Representations (ICLR 2025)*. <https://arxiv.org/abs/2501.13381> (실험) → 다중 에이전트 상황에서의 동조(H2·H4).
11. Yun, L., An, C., Wang, Z., Peng, L., & Shang, J. (2025). *The price of format: Diversity collapse in LLMs*. arXiv:2505.18949. <https://arxiv.org/abs/2505.18949> (프리프린트, 실험) → 구조화된 프롬프트 형식이 출력 다양성을 줄인다는 보고(H1).
12. Zheng, M., Pei, J., Logeswaran, L., Lee, M., & Jurgens, D. (2024). When "A helpful assistant" is not really helpful: Personas in system prompts do not improve performances of large language models. *Findings of the Association for Computational Linguistics: EMNLP 2024*. <https://arxiv.org/abs/2311.10054> (실험) → 페르소나가 정확도를 높이지 않는다는 보고(H3).
13. Zhu, X., Zhang, C., Stafford, T., Collier, N., & Vlachos, A. (2025). Conformity in large language models. *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (ACL 2025, Main)*. <https://arxiv.org/abs/2410.12428> (실험) → LLM이 다수 의견에 동조하며 불확실할수록 더 그렇다는 보고(H2).

목록에서 뺀 것. Zheng et al.의 초기 버전(2023, 반대 결론), 2차 요약 사이트, EmotionPrompt 계열 (기각한 가설). 자세한 이유는 `과정기록/02_문헌조사.md` 6절에 있다.