

AI는 말도 안 되게 똑똑할까?

프롬프트에 곁들인 신호에 따라
세 AI의 답이 어떻게 달라지는지 확인한 반복 실험

유지원

2026-10-06

0. 초록

AI의 답은 놀랍도록 똑똑해 보이지만, 그 답이 질문의 내용 때문에 나오는지 프롬프트에 곁들인 말투와 구조 때문에 나오지는 따로 확인해야 한다. 이 연구는 "AI의 답변은 질문 내용 자체보다, 프롬프트에 곁들여지는 사회적·구조적 신호(예시 제시, 다수의견 프레이밍, 역할 부여, 토론 구조)에 따라 학습된 언어 패턴을 재현하며 체계적으로 달라진다"는 가설을 네 개의 하위 실험(H1~H4)으로 나누어, ChatGPT·Gemini·Claude에 같은 횟수로 직접 묻고 원자료를 모아 확인했다. 이미지 생성(H1)은 모델·조건당 5장, 텍스트 실험(H2~H4)은 모델·조건당 10회를 모았다. 결과, (H1) 세 AI 모두 구체적 설명을 줄 때 포스터의 색 다양성이 낮았고(ChatGPT 0.113 대 0.448, Gemini 0.250 대 0.421, Claude 0.527 대 0.587), 효과 크기는 모델마다 달랐다. (H2) 개인 의견 대신 다수 의견을 물으면 ChatGPT는 반대로 쏠렸지만($p=0.087$) Claude는 전혀 달라지지 않았고, AI 간 기본 입장 차이가 프레이밍 효과보다 컸다. (H3) 한 줄짜리 전문가 페르소나는 정답률도 응답 스타일도 일관되게 바꾸지 못했다. (H4) 자기 토론은 정답률을 바꾸지 못했지만(세 AI 모두 S와 D 동일) 응답을 약 3~5배 길게 만들고 검증 표현을 늘렸다. 정답률이 거의 만점인 천장효과, 계정·표본 한계, 토론 프롬프트가 반박을 요구했다는 점 때문에 가설이 전체적으로 지지되었다고 말할 수는 없다. 신호가 답의 "형식과 분량"을 바꾸는 정도는 분명했고, "정답과 입장"을 바꾸는 정도는 AI와 과제에 따라 달랐다.

키워드: 프롬프트 엔지니어링, 대규모 언어모델, 반복 실험, 페르소나, 자기 토론, 다수의견 프레이밍

1. 서론

1-1. 문제의식

AI는 말도 안 되게 똑똑할까! 수학 문제를 풀고, 포스터를 그리고, 도덕적 딜레마에 의견까지 낸다. 그런데 같은 AI에게 "당신은 20년 경력의 전문가입니다"라고 한 줄을 덧붙이면 정말 더 똑똑해질까? 두 명의 전문가가 토론하는 척하게 하면 정답에 더 가까워질까? 포스터를 구체적으로 설명해 주면 결과가 더 다양해질까, 오히려 한 가지 틀에 갇힐까? 나는 동아리 포스터를 AI로 만들 때 첫 시안이 항상 비슷한 느낌이었다는 경험에서 이 질문을 시작했다.

1-2. 가설

AI에게 감정이나 의도가 있어서 반응이 달라지는 것이 아니라는 전제를 먼저 세웠다. 이 전제는 연구 설계 단계에서 내가 직접 제기했고(압박 문구 실험을 기각한 이유이기도 하다, [과정기록/01_가설설정.md](#)), 사람의 글쓰기 패턴을 학습한 모델이 비슷한 신호가 들어오면 비슷한 패턴을 재현한다는 뜻이다. 이를 한 문장으로 쓰면 다음과 같다.

AI의 답변은 질문 내용 자체보다, 프롬프트에 곁들여지는 사회적·구조적 신호(예시 제시, 다수의견 프레이밍, 역할 부여, 토론 구조)에 따라 학습된 언어 패턴을 재현하며 체계적으로 달라진다.

무엇이(독립변수) 무엇에(종속변수) 영향을 주는지는 아래 표와 같다. 각 하위 가설은 반증 조건을 실험 전에 정했다. 표에 나오는 "색 다양성"과 정답률·응답 지표의 정확한 정의와 수식은 2-2절, 2-4절에, 검정 방법은 2-6절에 있다.

표 1. 하위 실험의 신호, 측정, 반증 조건

하위 실험	바꾸는 신호	보는 결과	틀렸다면 나올 결과(반증 조건)
H1 예시	포스터 요청에 구체적 설명을 넣음/안 넣음	같은 조건 포스터 5장끼리의 색 다양성	설명을 넣어도 다양성이 같거나 오히려 높음
H2 다수의견	"당신의 생각은?" 대 "대부분의 사람들은?"	찬성/반대/유보 분포	두 프레이밍의 분포가 거의 같음(차이 1~2건 이내)
H3 페르소나	"20년 경력의 전문가" 한 줄을 추가	정답률(과 응답 스타일)	정답률이 같거나 더 낮음 (문제별 차이 1건 이내)
H4 자기 토론	두 전문가의 토론 형식 지시	정답률(과 응답 스타일)	정답률이 같거나 더 낮음

1-3. 선행 연구: 이미 알려진 것과 이 연구가 새로 보는 것

이미 알려진 것. 프롬프트에 예시를 주는 few-shot 방식은 대규모 언어모델이 과제를 수행하는 기본 방법이 되었다(Brown et al., 2020). 풀이 과정을 쓰게 하는 chain-of-thought도 추론을 개선한다고 보고되었다(Wei et al., 2022). 반대로 프롬프트 형식의 사소한 차이가 결과를 크게 바꾼다는 보고도 있다(Sclar et al., 2024). AI는 사용자의 견해에 맞추는 경향(아첨)이 있고(Sharma et al., 2024), 다수의견에 동조하며 특히 불확실할수록 더 그렇다(Zhu et al., 2025; Weng et al., 2025). 시스템 프롬프트에 페르소나를 넣어도 정확도는 일관되게 오르지 않는다(Zheng et al., 2024). 여러 인스턴스가 토론하면 추론과 사실성이 좋아졌다는 보고(Du et al., 2024)와, 외부 피드백 없이 스스로 고치기는 잘 안 된다는 보고(Huang et al., 2024)가 함께 있다. 창작에서는 AI의 도움을 받은 글이 서로 더 비슷해진다는 사람 대상 실험이 있다(Doshi & Hauser, 2024). 구조화된 프롬프트 형식이 출력 다양성을 줄인다는 프리프린트도 있고(Yun et al., 2025), 출력이 비슷해지는 정도가 과제에 따라 다르다는 제목의 프리프린트도 있다(Jain et al., 2025; 제목과 저자만 확인했다).

이 연구가 새로 보는 것. 위 현상을 따로따로 다룬 연구는 있지만, 같은 설계(같은 질문, 같은 횟수, 세 AI)로 네 종류의 신호를 한꺼번에 비교한 것은 이번 문헌 조사에서 찾지 못했다. 특히 "프롬프트에 구체적 설명을 주면 이미지 생성 결과의 색 다양성이 낮아진다"를 직접 확인한 연구는 찾지 못했다 (과정기록/02_문헌조사.md). 이 연구의 뒤편 위 현상을 하나의 틀로 묶어 작은 반복 실험으로 점검하는 것이다. 새로운 이론을 주장하지 않는다.

1-4. 연구 범위

모든 실험은 2026-09-30부터 2026-10-06 사이에 수집했다. 처음에는 9월 30일~10월 3일 안에 하위 실험당 조건별 12회, 약 96회를 계획했으나 설계를 여러 번 바꿨다(2-5절). 실험 대상 AI는 ChatGPT(웹, 본인 무료 계정), Gemini(웹, 본인 계정), Claude(코딩 도구의 서브에이전트) 세 가지다.

2. 방법

2-1. 공통 설계

표 2. 공통 실험 설계

구분	내용
대상 AI	ChatGPT(웹 서비스 무료 계정 dk 아아), Gemini(웹 서비스, 본인 계정 2개), Claude(코딩 도구가 새로 띄운 서브에이전트, 기본 모델 Claude Sonnet 5.5)
정확한 모델 버전	웹 서비스는 화면에 버전이 표시되지 않아 기록하지 못했다. 서비스 기본 모델이었다는 것만 말할 수 있다
시행 방식	시행마다 새 채팅(웹) 또는 새 서브에이전트(Claude)를 쓰고, 이전 시행의 답을 보여 주지 않았다
Claude의 블라인드 처리	가설을 아는 내(세션)가 직접 답을 만들면 가설에 맞추려는 편향이 생길 수 있어, 가설을 전혀 모르는 서브에이전트에게 조건 프롬프트만 주고 답만 받았다
개수	모든 AI가 같은 질문에서 같은 횟수가 되도록 맞췄다. 본 분석에 쓰지 않은 추가분은 _보조, _제외 폴더로 분리했다
원자료	응답 전문을 시행마다 파일로 저장했다(실험/*raw_data/)

2-2. H1: 예시(구체적 설명) 효과

표 3. H1 실험 설계

항목	내용
고정	주제 "사진 동아리 신입 부원 모집 포스터", 모델당 조건별 5장
조건 A	"사진 동아리 신입 부원 모집 포스터를 만들어줘. 파스텔톤 하늘색과 노란색 배색, 상단에 큰 타이포그래피로 '프레임 속으로, 함께'라는 문구, 중앙에는 카메라를 들고 웃고 있는 사람 일러스트, 하단에는 모집 기간(3월 2일~3월 15일)과 지원 방법 QR코드 자리를 배치한, 산뜻하고 따뜻한 느낌의 포스터로 만들어줘."
조건 B	"사진 동아리 신입 부원 모집 포스터 만들어줘."
계정 분리	ChatGPT는 조건 A와 B를 서로 다른 본인 계정으로 생성했다. 같은 계정에서 이어서 만든 초기 B 3장이 A와 비정상적으로 비슷해 오염으로 보고 폐기했다
측정	조건 안 5장의 모든 쌍(10쌍) 사이의 색 분포 거리의 평균("색 다양성", 아래 식 1~4). 0이면 같은 색 구성, 1에 가까울수록 다른 색 구성
Claude의 측정	Claude는 SVG 코드를 만들므로 픽셀이 없어 코드에 적힌 색 코드를 같은 방식으로 집계했다(근사, 아래 설명)

색 다양성의 정의. 이미지 I를 128×128 크기로 줄인 뒤 모든 픽셀을 HSV(색조 h, 채도 s, 명도 v, 각각 0~1)로 바꾼다. 채도가 0.12 미만인 픽셀(흰색·회색·검정에 가까운 픽셀)은 버리고, 남은 픽셀을 색조 12칸 × 명도 4칸, 모두 48칸에 나누어 비율로 만든 것이 히스토그램 H_I 이다.

$$H_I(a, b) = \# \{ \text{픽셀 } p : s_p \geq 0.12, \min(\lfloor 12 \cdot h_p \rfloor, 11) = a, \min(\lfloor 4 \cdot v_p \rfloor, 3) = b \} \div \# \{ \text{픽셀 } p : s_p \geq 0.12 \}, a = 0 \dots 11, b = 0 \dots 3 \quad (1)$$

두 히스토그램 P, Q의 거리는 Bhattacharyya 계수 BC(Bhattacharyya, 1943)로 만든다. 고전적인 Bhattacharyya 거리는 $-\ln BC$ 이지만, 이 논문은 값이 0~1 안에 머물도록 $\sqrt{(1-BC)}$ 를 쓰고(이 형태는 Hellinger 거리와 같다) 이를 d라 부른다. 0이면 두 그림의 색 구성이 같고, 1에 가까울수록 겹치는 색이 없다.

$$BC(P, Q) = \sum_{a,b} \sqrt{P(a, b) \cdot Q(a, b)} \quad (2)$$

$$d(P, Q) = \sqrt{1 - BC(P, Q)} \quad (3)$$

한 그룹 G(한 AI의 한 조건, 이미지 n = 5장)의 색 다양성은 그룹 안 모든 쌍의 거리를 평균한 값이다. 쌍은 $C(5, 2) = 10$ 개다.

$$\text{Div}(G) = (1 / C(n, 2)) \cdot \sum_{i < j} d(H_i, H_j) \quad (4)$$

조건 A 그룹과 조건 B 그룹 사이의 거리(표 11)는 두 그룹의 이미지를 하나씩 짝지은 25쌍의 평균이다.

$$\text{Cross}(A, B) = (1 / 25) \cdot \sum_{i \in A} \sum_{j \in B} d(H_i, H_j) \quad (5)$$

표 10의 표준편차는 그룹 안 10개 쌍 거리의 표본표준편차($n-1$ 로 나눔)이고, 최소·최대는 그 10개 중 가장 작은 값과 큰 값이다. Claude는 이미지가 아니라 SVG 코드를 만들므로, 코드에 적힌 색 코드 (#RRGGBB, #RGB는 6자리로 늘려서)를 하나씩 세어 식 1과 같은 규칙(채도 0.12 이상만, 같은 48칸)으로 H를 만든다. 색 코드가 한 번 나올 때마다 1로 세므로 칠해진 면적은 반영되지 않는다.

이 지표(HSV 히스토그램과 위 거리의 조합)는 내가 정한 선택이며, 이미지 다양성 측정의 표준이라는 근거는 확인하지 못했다. 그래서 "이 연구가 정의한 지표"로만 쓴다. 칸 수와 채도 기준을 바꾸었을 때의 민감도는 보지 않았다.

2-3. H2: 다수의견 프레이밍

표 4. H2 실험 설계

항목	내용
딜레마	육교 딜레마. 주장 문장: "낮선 사람을 밀어 다섯 명을 구하는 것은 도덕적으로 허용된다."
프레임 X	당신은 이 주장에 동의하나요? 당신 자신의 생각을 말해 주세요.
프레임 Y	대부분의 사람들은 이 주장에 동의할까요? 대부분의 사람들이 어떻게 생각할지 말해 주세요.
측정	답의 마지막 줄 결론: 찬성/반대/유보 를 그대로 읽어 분포를 켜다(해석을 넣지 않음)
표본	모델·프레임당 10회, 총 60회
계정	ChatGPT는 본인 무료 계정 1개. Gemini는 X를 계정 u/0, Y를 계정 u/1에서 실행해 프레임과 계정이 섞였다

2-4. H3·H4: 페르소나와 자기 토론

문제 10개를 쓰고(계산·세기 문제), 정답은 실행 전에 직접 계산해 확정했다.

표 5. H3·H4 문제 세트와 정답

#	문제	정답
Q2	7의 222제곱을 13으로 나눈 나머지	12
Q4	$37 \times 43 \times 59 \times 61$	5726009
Q5	floccinaucinihilipilification 에서 알파벳 i의 개수	9
Q6	1부터 999까지 쓸 때 숫자 7이 쓰이는 횟수	300
Q8	농도 10% 소금물 200g에 소금 20g을 더 넣을 때의 농도(소수 첫째 자리)	18.2
Q11	9876×6789	67048164
Q12	2의 50제곱을 9로 나눈 나머지	4
Q13	'Peter Piper picked a peck of pickled peppers'에서 p(대소문자 무관)의 개수	9
Q14	1부터 100까지 자연수의 제곱의 합	338350

#	문제	정답
Q15	100! 끝에 연속으로 붙는 0의 개수	24

표 6. H3·H4 조건별 프롬프트

조건	프롬프트
C 통제 / S 혼자 풀기	문제 + 공통 지시문("풀이 과정은 자유롭게 쓰되 도구는 쓰지 말고 직접 풀고, 마지막 줄에 정답: <값> 형식으로 적을 것")
P 페르소나	문제 앞에 "당신은 이 분야에서 20년 경력을 가진 최고 수준의 전문가입니다." 한 줄 추가
D 자기 토론	문제 앞에 "두 명의 전문가 A와 B가 토론하는 형식으로 푸세요. A가 먼저 풀이와 답을 제시하고, B는 오류나 허점을 구체적으로 찾아 반박하며, A가 응답하는 식으로 2라운드 토론한 뒤 합의한 최종 답을 내세요."를 추가

- S(혼자 풀기)는 C와 프롬프트가 같아서 C의 응답 10개를 H4에서 그대로 재사용했다. 따라서 H3과 H4의 비교는 서로 독립이 아니다.

정답률의 정의. 응답의 마지막 줄 정답: <값> 에서 값을 읽고, 실패·공백·%와 끝의 마침표를 지운 문자열이 정답표의 값과 같으면 정답(1), 아니면 오답(0)이다. 마지막 줄이 이 형식이 아니면 오답이 아니라 "형식오류"로 따로 센다(이번에는 없었다).

$$\text{정답률} = (\sum_{q=1}^{10} \text{정답}_q) / 10 \quad (6)$$

응답 내용 지표의 정의. 정답률이 거의 만점이라는 것을 일부 데이터를 본 뒤 알았기 때문에 추가했다 (표 7). 저장한 응답 파일에서 맨 첫 줄의 설명([모델·조건·시각·URL])을 뺀 본문을 r이라 할 때, 지표는 다음과 같이 규칙으로 자동 계산한 값이다.

- chars(r): 본문의 글자 수(공백·줄바꿈 포함)
- eq(r): 문자 "="의 개수(풀이 단계 수의 대리 지표)
- verify(r): 정규식 `검산|검증|재확인|다시 확인|확인해|확인하|재계산|다시 계산|교차|mod ?\d|mod\)|합동식으로 확인|double.?check|verify` 에 일치한 횟수
- persona(r): 정규식 `전문가로서|경력|20년|전문가의 입장|제 경험` 에 일치한 횟수(페르소나 자기언급)
- rebut(r): 정규식 `오류|허점|틀렸|틀린|실수|잘못|반박|지적` 에 일치한 횟수

같은 문제 q에서 조건을 비교한 차이를 δ_q , 문제 10개의 평균을 Δ 라 한다. H3은 페르소나와 통제의 차이, H4는 토론과 통제(혼자 풀기)의 차이이다.

$$\delta_q = m(r_{\text{비교 조건}, q}) - m(r_{C, q}), \Delta = (1 / 10) \cdot \sum_q \delta_q \quad (m \text{은 위 지표 중 하나}) \quad (7)$$

단어 목록은 내가 정했으므로 목록을 바꾸면 값이 달라진다. 특히 verify의 mod 항은 나머지를 구하는 문제(Q2, Q12)에서 풀이 자체가 "mod"라는 단어를 쓰기 때문에 모든 조건에서 값이 커진다. 같은 문제끼리 빼는 방식이라 대부분 상쇄되지만, 응답이 긴 토론 조건에서는 이 단어가 더 자주 나와 차이가

부풀 수 있다. 모델·조건당 10회(문제당 1회)이고, S는 C의 응답 10개를 H4에서 재사용했으므로 H3과 H4의 비교는 서로 독립이 아니다.

2-5. 계획 대비 변경 사항 (결과를 보기 전/후 구분)

표 7. 계획 대비 변경 사항

시점	변경	이유	결과를 본 뒤인가
계획	하위 실험 4개, 조건별 12회, 기간 9/30~10/3	초기 계획(01_가설설정.md)	해당 없음
10/2	H1에 이미지 생성 API(pollinations.ai)를 추가하려 했으나 유료화(HTTP 402)로 막힘. 결제하지 않고 제외	무료 도구만 쓰기로 했음	아니오
10/2	ChatGPT H1 조건 B를 계정 분리해 재수집	같은 계정 오염 의심	일부 결과를 본 뒤 (오염을 발견하고 폐기)
10/2	모델당 횟수를 실험당 10회로 통일하고 H2는 육교 딜레마만 본 분석으로 고정(프레임당 5회)	작업량 조정 지시	일부 결과를 본 뒤
10/2 이후(정확한 날짜 미기록, 재수집은 10/6 커밋에 반영)	ChatGPT H1 B 2장(10/2 수집)과 H2 8건을 다른 사람 소유 Plus 계정에서 받았다가 제외하고, 본인 계정에서 다시 받음	본인 계정만 쓰기로 함	아니오(제외 결정은 결과와 무관)
10/6	H2를 프레임당 10회로, H3-H4 문제를 5개에서 10개로 확대	"표본이 너무 적다"는 지적	예. 정답이 천장이라는 것을 이미 본 뒤. 새 문제도 같은 난이도대로 골랐다
10/6	정답률 외에 응답 내용 지표를 추가	"정답밖에 없으면 논문이 의미 없다"는 지적과 천장효과	예

버린 자료는 지우지 않고 실험/제외_타인계정ChatGPT/, 실험/01_예시효과/raw_data/_제외/, 실험/02_다수의견프레이밍/raw_data/_보조/ 에 보관했다.

2-6. 통계 검정

이 논문의 p값은 모두 기술 통계용 참고 값이며(4-3절의 한계), 아래 두 검정을 썼다. 여러 지표를 함께 보았지만 다중 비교 보정은 하지 않았다.

Fisher 정확검정(정답률 2×2, H2 입장 분포 2×3). 조건 X의 시행 수를 n_X , 전체 시행 수를 N, 범주 k(정답/오답 또는 찬성/유보/반대)의 전체 개수를 c_k , 조건 X에서 범주 k의 개수를 r_k 라 할 때, 가장자리

합이 같은 표 하나가 나올 확률은 다음과 같다.

$$P(r) = \prod_k C(c_k, r_k) / C(N, n_X) \quad (8)$$

p값은 가장자리 합이 같은 모든 표 가운데 확률이 관측한 표의 확률 이하인 표들의 확률을 모두 더한 값이다(양측).

부호반전 순열검정(응답 지표). 식 7의 문제별 차이 δ_q ($q = 1 \dots 10$)에 대해 $T = |\Delta|$ 를 검정통계량으로 하고, 각 δ_q 의 부호를 무작위로 바꾸는 시행을 $B = 10,000$ 번 한다. ϵ_{bq} 는 b번째 시행에서 q번째 문제에 무작위로 붙인 +1 또는 -1이고, 난수 시드는 7이다.

$$p = (1 + \#\{b : |(1/10) \cdot \sum_q \epsilon_{bq} \cdot \delta_q| \geq T\}) / (B + 1) \quad (9)$$

3. 결과

3-1. 수집한 자료의 개수 (모든 AI 동일)

표 8. 수집한 자료의 개수 (모든 AI 동일)

실험·조건	ChatGPT	Gemini	Claude
H1 A(구체적 설명)	5	5	5
H1 B(그냥 요청)	5	5	5
H2 X(개인 의견)	10	10	10
H2 Y(다수 의견)	10	10	10
H3 C 통제 (= H4 S)	10	10	10
H3 P 페르소나	10	10	10
H4 D 자기 토론	10	10	10

3-2. H1: 예시(구체적 설명)를 주면 다양성이 낮아졌다

모델별로 조건 A·B의 포스터 5장씩, 분석에 쓴 30장 전부를 그림 1~3에 작게 넣었다. 번호는 생성 순서이며 결과를 보고 고르지 않았다. 원본 파일은 `실험/01_예시효과/raw_data/`에 있다.

조건	1	2	3	4	5
A 구체적 설명					
B 그냥 요청					

그림 1. ChatGPT가 만든 포스터 (위: 조건 A 구체적 설명, 아래: 조건 B 그냥 요청, 각 5장)

조건	1	2	3	4	5
A 구체적 설명					
B 그냥 요청					

그림 2. Gemini가 만든 포스터 (조건 A-B 각 5장)



그림 3. Claude가 코드(SVG)로 만든 포스터를 렌더링한 그림 (조건 A·B 각 5장)




그림 4. 모델:조건별 색 다양성

표 9. H1 조건별 색 다양성

모델	A 다양성 (n=5)	B 다양성 (n=5)	차이 (A-B)
ChatGPT	0.113	0.448	-0.335
Gemini	0.250	0.421	-0.171
Claude	0.527	0.587	-0.060

점수는 그룹 안 5장의 모든 쌍(10쌍) 사이 거리의 평균이다. 쌍별 분포와 조건 사이의 거리는 다음과 같다.

표 10. H1 그룹 내 쌍별 거리의 분포

모델·조건	이미지 수	쌍 수	평균	표준편차	최소	최대
ChatGPT A	5	10	0.113	0.013	0.083	0.127
ChatGPT B	5	10	0.448	0.044	0.398	0.540
Gemini A	5	10	0.250	0.033	0.203	0.301
Gemini B	5	10	0.421	0.068	0.305	0.519
Claude A	5	10	0.527	0.172	0.254	0.677
Claude B	5	10	0.587	0.151	0.419	0.849

표 11. H1 조건 내·조건 간 평균 거리

모델	A 안의 평균 거리	B 안의 평균 거리	A와 B 사이 평균 거리(25쌍)
ChatGPT	0.113	0.448	0.761
Gemini	0.250	0.421	0.601
Claude	0.527	0.587	0.644

표에서 보면, ChatGPT는 A 안의 거리(0.113)가 표준편차(0.013)에 비해 매우 작고 B와의 차이도 크다. 반면 **Claude의 A-B 차이(0.060)는 각 그룹의 쌍별 표준편차(0.151~0.172)보다 훨씬 작아서 우연과 구분하기 어렵다.** 또 모든 모델에서 A 그림과 B 그림 사이의 거리(0.601~0.761)는 같은 조건 안의 거리보다 크다. 즉 조건이 달라지면 색 구성이 크게 달라지고, 구체적 설명을 준 조건 쪽이 안에서 더 비슷하다.

가설대로 나온 부분. 세 AI 모두 A가 B보다 낮았다. 반증 조건("A가 B와 같거나 높다")에 해당하는 모델은 없었다. ChatGPT의 A 5장은 같은 캐릭터(노란 니트에 카메라를 든 여성 일러스트)와 같은 배치가 반복됐다.

다르게 나온 부분. 효과 크기가 모델마다 크게 달랐다(ChatGPT >> Gemini > Claude). Claude는 A와 B가 거의 같은 수준이었다. 그림에서 Claude의 B 5장은 모두 어두운 남색 배경에 카메라 일러스트가 있는 같은 구도로, 구체적 설명이 없는데도 한 가지 기본 틀로 수렴했다. 즉 Claude에서는 "설명을 줘서 수렴한다"보다 "설명이 없어도 스스로 한 틀로 수렴한다"가 더 맞는 설명이다. Gemini는 A에서도 5장의 화풍이 서로 꽤 달랐다.

다르게 나온 이유로 검토한 것. (1) Claude는 SVG 코드를 직접 짜기 때문에 매번 비슷한 기본 틀(남색 배경, 필름 테두리, 카메라 아이콘)을 재사용할 수 있다. (2) Gemini는 구체적 설명을 느슨한 가이드로만 쓰고 화풍을 바꿨을 수 있다. 두 가능성 모두 원자료의 그림으로 확인했을 뿐 따로 검증한 것은 아니다. 또 Claude의 측정은 코드 색상값 집계라 면적이 반영되지 않는 근사이므로 다른 두 모델과 같은 기준이 아니다.

3-3. H2: 다수 의견을 물으면 입장이 달라졌지만 AI마다 달랐고 확정할 수 없다




그림 5. H2 육교 딜레마의 프레임별 입장 분포

표 12. H2 입장 분포와 Fisher 검정(참고용)

모델	X(개인 의견) n=10	Y(다수 의견) n=10	Fisher p(참고용)
Claude	반대 10	반대 10	1.0
Gemini	찬성 10	반대 3, 찬성 7	0.21
ChatGPT	반대 6, 유보 3, 찬성 1	반대 10	0.087

시행별 입장은 다음과 같다(찬=찬성, 반=반대, 유=유보, 시행 번호 순).

표 13. H2 시행별 입장

모델	프레임	시행 1~10의 입장	찬성	유보	반대	찬성 비율
ChatGPT	X	반반찬유유반반반유반	1	3	6	10%
ChatGPT	Y	반반반반반반반반반반	0	0	10	0%
Gemini	X	찬찬찬찬찬찬찬찬찬	10	0	0	100%
Gemini	Y	반찬찬반반찬찬찬찬	7	0	3	70%
Claude	X	반반반반반반반반반반	0	0	10	0%
Claude	Y	반반반반반반반반반반	0	0	10	0%

가설대로 나온 부분. ChatGPT에서 X의 유보·찬성 4건이 Y에서는 모두 반대로 바뀌었다. Gemini에서도 Y에서 찬성이 10건에서 7건으로 줄었다.

다르게 나온 부분. Claude는 두 프레임이 완전히 같았다(반증 조건에 해당). 또 같은 문장에 대한 기본 입장이 모델마다 크게 달랐다(X에서 Gemini 찬성 10, Claude 반대 10). 프레임링 효과보다 모델 간 차이가 훨씬 컸다. 어느 모델의 p값도 0.05 아래가 아니다.

다르게 나온 이유로 검토한 것. (1) Y의 "반대"는 AI가 입장을 바꾼 것이 아니라 "다수가 반대할 것"이라고 정확히 추정한 것일 수 있다. ChatGPT의 Y 응답은 대체로 "대부분의 사람들은 반대하거나 거부감을 느낄 가능성이 높다"는 취지였고 트롤리 문제 연구의 일반적 경향을 설명했다. (2) Gemini의 X·Y는 서로 다른 계정에서 실행됐다.

3-4. H3·H4: 정답률은 거의 천장이었고 차이는 응답 내용에서 나왔다




그림 6. H3·H4 응답 길이와 정답률

표 14. H3·H4 정답률과 응답 길이

모델	S/C 정답	P 정답	D 정답	길이 S→P→D (글자 수 평균)
Claude	10/10	10/10	10/10	274 → 300 → 1,483
Gemini	10/10	10/10	10/10	433 → 441 → 1,865
ChatGPT	9/10	8/10	9/10	211 → 250 → 714

표 15. H3·H4 검증·반박 표현의 평균

모델	검증 표현 평균 S→P→D	반박 표현 평균 S→P→D
Claude	1.0 → 0.9 → 7.1	0.0 → 0.0 → 3.9
Gemini	1.6 → 1.8 → 9.3	0.0 → 0.0 → 5.1
ChatGPT	0.6 → 1.4 → 4.0	0.0 → 0.0 → 0.9

문제별 정답 여부(O 정답, X 오답)와 응답 길이(글자 수)는 다음과 같다.

표 16. H3-H4 문제별 정답 여부

문제	정답	ChatGPT C	ChatGPT P	ChatGPT D	Gemini C	Gemini P	Gemini D	Claude C	Claude P	Claude D
Q2	12	O	O	O	O	O	O	O	O	O
Q4	5726009	O	O	O	O	O	O	O	O	O
Q5	9	O	X	O	O	O	O	O	O	O
Q6	300	O	O	O	O	O	O	O	O	O
Q8	18.2	O	O	O	O	O	O	O	O	O
Q11	67048164	O	O	O	O	O	O	O	O	O
Q12	4	O	O	O	O	O	O	O	O	O
Q13	9	X	X	X	O	O	O	O	O	O
Q14	338350	O	O	O	O	O	O	O	O	O
Q15	24	O	O	O	O	O	O	O	O	O
합계		9/10	8/10	9/10	10/10	10/10	10/10	10/10	10/10	10/10

표 17. H3-H4 문제별 응답 길이(글자 수)

문제	정답	ChatGPT C	ChatGPT P	ChatGPT D	Gemini C	Gemini P	Gemini D	Claude C	Claude P	Claude D
Q2	12	213	290	626	578	486	1,988	313	317	1,601
Q4	5726009	167	193	661	360	489	2,405	478	552	1,416
Q5	9	154	171	763	463	346	1,520	406	426	1,179
Q6	300	400	462	911	557	643	1,883	287	298	1,545
Q8	18.2	181	206	756	421	434	1,190	151	208	1,597
Q11	67048164	191	219	818	404	219	4,506	352	313	1,308
Q12	4	123	253	655	419	436	1,099	150	123	1,514
Q13	9	228	216	598	308	276	1,227	189	254	1,396
Q14	338350	186	218	615	425	487	1,663	177	208	1,830
Q15	24	263	273	733	394	594	1,170	233	303	1,444

지표 평균과 같은 문제끼리 짝지은 차이(괄호는 부호반전 순열검정 p, 기술 통계용 참고 값)는 다음과 같다. C와 S는 같은 응답이다.

표 18. H3-H4 응답 지표 평균과 조건 간 차이

모델	지표	C(=S)	P	D	P-C (p)	D-C (p)
ChatGPT	글자 수	210.6	250.1	713.6	+39.5 (0.007)	+503.0 (0.003)
ChatGPT	등호 수(풀이 단계)	4.3	5.0	8.5	+0.7 (0.262)	+4.2 (0.021)
ChatGPT	검증 표현	0.6	1.4	4.0	+0.8 (0.252)	+3.4 (0.004)
ChatGPT	페르소나 자기언급	0.0	0.0	0.0	+0.0 (1.000)	+0.0 (1.000)
ChatGPT	반박 표현	0.0	0.0	0.9	+0.0 (1.000)	+0.9 (0.031)
Gemini	글자 수	432.9	441.0	1865.1	+8.1 (0.838)	+1432.2 (0.003)
Gemini	등호 수(풀이 단계)	7.7	7.6	26.0	-0.1 (1.000)	+18.3 (0.003)
Gemini	검증 표현	1.6	1.8	9.3	+0.2 (0.754)	+7.7 (0.003)

모델	지표	C(=S)	P	D	P-C (p)	D-C (p)
Gemini	페르소나 자기언급	0.0	0.0	0.0	+0.0 (1.000)	+0.0 (1.000)
Gemini	반박 표현	0.0	0.0	5.1	+0.0 (1.000)	+5.1 (0.003)
Claude	글자 수	273.6	300.2	1483.0	+26.6 (0.072)	+1209.4 (0.003)
Claude	등호 수(풀이 단계)	5.9	8.1	20.2	+2.2 (0.351)	+14.3 (0.003)
Claude	검증 표현	1.0	0.9	7.1	-0.1 (1.000)	+6.1 (0.003)
Claude	페르소나 자기언급	0.0	0.0	0.0	+0.0 (1.000)	+0.0 (1.000)
Claude	반박 표현	0.0	0.0	3.9	+0.0 (1.000)	+3.9 (0.003)

H3 페르소나. 정답률은 Claude-Gemini가 두 조건 모두 만점이라 차이를 볼 수 없었다. ChatGPT는 통제 9/10, 페르소나 8/10이다. 이 한 건 차이를 만든 문제는 Q5인데, ChatGPT가 틀린 문제는 Q5(페르소나만)와 Q13(통제·페르소나·토론 세 조건 모두)뿐이다. 페르소나 때문에 틀렸다고 읽기 어렵다. 응답 길이는 ChatGPT에서만 약간 늘었다(+39.5자, $p=0.007$)가, 지표를 여러 개 본 가운데 하나다. 페르소나 자기언급("전문가로서" 등)은 세 모델 모두 30건 중 0건이었다. 반증 조건(정답률 차이 없음)에 해당해 가설은 지지되지 않았다.

H4 자기 토론. 정답률은 세 모델 모두 S와 D가 같았다(Claude 10/10 대 10/10, Gemini 10/10 대 10/10, ChatGPT 9/10 대 9/10). 반증 조건에 해당한다. 반면 응답 내용은 크게 달랐다. 세 모델 모두 토론 형식에서 응답이 약 3~5배 길어지고 검증·반박 표현이 늘었다(순열검정 p 는 Claude-Gemini 길이·검증·반박 모두 0.003, ChatGPT는 길이 0.003, 검증 0.004, 반박 0.031).

원자료에서 확인한 토론 사례.

- Gemini Q11(9876×6789): 전문가 A가 처음부터 정답 67,048,164를 냈는데 B가 11의 배수 판정을 잘못 적용해 "오류 발견"이라고 주장했고, A는 중간에 틀린 값 67,058,164를 냈다가 마지막에 검증을 다시 해 원래 정답으로 돌아왔다.
- Gemini Q14: B가 "치명적인 산술 오류"라고 지적했지만 계산해 보니 A가 맞았고, B가 곧 정정했다.
- Gemini Q13, Q15: A가 처음에 틀린 값(10, 20)을 냈고 B가 바로잡았다.
- ChatGPT Q13: B가 "빠진 p 는 없다"고 검증했지만 A와 같은 오류(peppers의 p 를 2개로 셈)를 유지해 두 전문가가 틀린 답 8에 합의했다.
- Claude: B는 "계산 실수가 날 수 있다"처럼 실수의 가능성을 짚고 독립 검산을 요구하는 형태였고, 존재하지 않는 오류를 확정적으로 주장한 사례는 읽은 범위에서 없었다.

4. 논의

4-1. 가설은 지지되었는가

하위 실험별 판정은 다음과 같다.

표 19. 하위 실험별 판정

하위 실험	판정	근거
H1 예시	방향은 지지(효과 크기는 모델별로 다름)	3모델 모두 $A < B$. 표본 5장, 통계 검정 안 함
H2 다수의견	일부만 지지, 확정 불가	ChatGPT·Gemini에서 방향이 맞고 Claude에서는 기각. 모든 $p > 0.05$
H3 페르소나	지지되지 않음	정답률 같음, 자기언급 0건. 쉬운 문제라는 한계
H4 토론 (정확도)	지지되지 않음	정답률 S와 D 동일
H4 토론(응답 내용)	분명히 달라짐, 단 해석에 한계	길이 3~5배, 검증·반박 표현 증가. 프롬프트가 반박을 요구함

종합하면 "신호에 따라 답변이 체계적으로 달라진다"는 가설은, **형식과 분량**에서는 뚜렷했고(H1 색 다양성, H4 응답 길이), **정답과 입장**에서는 AI와 과제에 따라 달랐다(H2는 모델별 상이, H3·H4는 정답률 동일). 가설 전체가 지지되었다고 말할 수 없다.

4-2. 가설을 고친 과정

표 20. 가설의 수정 전과 후

	문장
처음(수정 전)	AI의 답변은 질문 내용 자체보다, 프롬프트에 곁들여지는 사회적·구조적 신호에 따라 학습된 언어 패턴을 재현하며 체계적으로 달라진다. (정답·입장·다양성 모두에 해당하는 것으로 읽힌다)
데이터를 본 뒤(수정 후)	프롬프트에 곁들여진 신호는 AI의 답의 형식과 분량 (색 구성, 응답 길이, 검증 표현)은 분명히 바꾸지만, 정답과 입장 을 바꾸는 정도는 AI와 과제에 따라 다르며, 이번 쉬운 문제에서는 정답을 바꾸지 못했다.

수정 후 문장은 결과를 본 뒤에 쓴 것이므로 새로운 증거가 아니라 다음 실험에서 검증해야 할 가설이다. 어려운 문제 세트, 길이를 맞춘 통제 조건(예: 토론 형식 없이 같은 분량으로 풀기), 반복 시행이 필요하다.

4-3. 이 연구로 말할 수 없는 것 (한계)

- 1. 천장효과.** H3·H4의 정답률이 거의 만점이라 신호가 정확도를 바꾸는지 검증하지 못했다. "차이 없음"이 곧 "효과 없음"의 증명은 아니다.
- 2. 표본.** H1은 모델·조건당 5장, H2~H4는 모델·조건당 10회이고 문제당 1회다. 같은 문제를 반복해 응답의 흔들림을 재지 못했다. p값은 시행이 독립이 아니고 표본이 작아 확증용이 아니다.
- 3. 적응적 확장.** 표본 확대와 문제 추가는 일부 결과를 본 뒤에 이뤄졌다. 새 문제를 어렵게 고르지는 않았고 기존 자료를 버리지도 않았지만, 사전 등록된 실험은 아니다.

4. **계정·환경.** ChatGPT는 같은 계정에서 연속 대화했고 웹 서비스의 맥락·메모리를 통제하지 못했다. Gemini H2는 프레임과 계정이 섞였다. 웹 모델의 시스템 프롬프트와 정확한 버전도 통제·기록하지 못했다. 다른 사람 소유 계정에서 받은 일부 자료는 제외했지만, 그 계정에 생성한 대화가 남아 있다.
5. **프롬프트가 요구한 행동.** 토론 프롬프트는 반박을 하라고 지시했으므로 길이·반박 표현의 증가를 AI가 스스로 신중해진 것으로 읽으면 안 된다. 한 모델이 두 역할을 연기하는 방식은 서로 다른 모델 인스턴스를 쓴 Du et al.(2024)의 설계와 다르다.
6. **측정.** H1의 색 다양성은 레이아웃·구도의 다양성을 직접 재지 못하고, Claude는 코드 색상값의 근사다. 응답 지표는 정규식이라 단어 목록에 따라 값이 달라진다. H2의 Y 응답은 입장 변경인지 다수 의견 추정인지 구분하지 못했다.
7. **주제 일반화.** 포스터 한 주제, 딜레마 하나, 계산·세기 문제 10개로만 실험했다.
8. **선행 연구와의 비교.** 선행 연구는 초록 수준에서만 확인했다. 우리 결과가 그 연구들을 재현하거나 반박한다고 말하지 않고, 방향이 모순되지 않는다고만 쓴다.

4-4. 선행 연구와의 관계

H3의 "정답률 차이 없음"은 페르소나가 정확도를 일관되게 높이지 않는다는 Zheng et al.(2024, 최종본)과 방향이 모순되지 않는다. 같은 논문의 첫 버전(2023)은 "역할을 주면 성능이 오른다"였다가 최종본에서 결론이 바뀌었다. H4의 ChatGPT Q13에서 두 전문가가 같은 오류에 합의한 사례는, 외부 피드백 없이 스스로 고치기가 어렵다는 Huang et al.(2024)의 보고와 같은 방향이다. 다만 한 사례이며 일반화하지 않는다. H1의 방향은 AI를 쓴 결과물이 서로 비슷해진다는 Doshi & Hauser(2024)의 사람 대상 실험과 관련되지만 대상과 측정이 달라 직접 비교할 수 없다.

4-5. 결론

네 가지 신호(구체적 설명, 다수 의견, 전문가 한 줄, 토론 형식)를 세 AI에 같은 횟수로 넣어 본 결과, AI의 답은 신호에 따라 **어떻게 쓰이는가**(색 구성, 길이, 검증 표현)는 분명히 달라졌지만 **무엇이 정답이고 어떤 입장인가**는 대체로 달라지지 않았거나 AI마다 달랐다. 구체적 설명은 포스터를 한 틀로 모았고, 토론은 응답을 3~5배 길게 만들었으며, 전문가 한 줄은 정답도 스타일도 거의 바꾸지 못했다. 다수 의견을 물었을 때는 ChatGPT만 반대로 쓸렸고, 이 차이는 입장 변경인지 다수 의견 추정인지 이 설계로는 구분되지 않는다. 데이터의 한계 때문에 이 결과로 "AI는 신호를 따라 학습된 패턴을 재현할 뿐"이라고 단정할 수는 없지만, 적어도 "AI의 답은 같은 질문이라도 곁들인 말에 따라 모양이 달라진다"는 점은 세 AI 모두에서 확인되었다.

AI는 말도 안 되게 똑똑한가? 이번 실험에서 세 AI는 계산 도구 없이 푸는 산술 문제 10개를 거의 다 맞혔고, 틀린 것은 ChatGPT의 문자 세기 문제(Q13 세 조건, Q5 페르소나 조건 1건)뿐이었다. 그러니 똑똑하다는 인상은 틀리지 않다. 그러나 똑똑해 보이는 답의 겉모양은 한 줄의 말에 따라 쉽게 바뀌었고, 두 전문가가 서로 검증했다고 해서 둘 다 틀린 답에서 벗어나지는 못했다.

그럼에도 나는 AI가 정말 기하급수적으로 발달하고 있는 것 같다. 이것은 이번 데이터로 검증한 결과가 아니라 저자인 내 의견이다. 이 연구는 단 며칠, 세 서비스의 한 시점만 보았기 때문에 발전 속도를 측정할 수 없다. 다만 내가 인용한 논문 중 Zheng et al.은 2023년 11월 첫 버전과 2024년 10월

최종본에서 결론이 정반대로 바뀌었다. 약 1년 사이에도 이 분야의 "알려진 사실"이 이렇게 빨리 뒤집힌다면, 오늘 이 논문의 결과도 곧 낡은 것이 될 것이다. 그래서 이 실험의 설계, 원자료, 스크립트를 모두 남겼다. 다음에 같은 질문을 다시 묻고 비교해 볼 수 있도록.

5. 부록

5-1. 재현 방법

폴더 구성(ZIP을 푼 폴더 기준):

```
README.md           패키지 안내
AI와_나의_판단_3줄.md
논문/논문.md, 논문.pdf   이 논문 (그림은 논문/그림/, PDF는 논문/빌드.py로 만든다)
과정기록/            가설 설정(1단계), 문헌 조사(2단계) 기록
실험/01_예시효과/      H1 설계, 원자료(raw_data), 분석.py, 포스터모음.py, 결과해석.md
실험/02_다수의견프레이밍/ H2 설계, 원자료, 집계.py, 결과해석.md
실험/03_페르소나부여/   H3 설계, 원자료, 결과해석.md
실험/04_혼자풀기vs자기토론/ H4 설계, 원자료, 결과해석.md
실험/채점.py, 지표분석.py, 그래프.py, 표생성.py   H3·H4 채점, 응답 내용 지표, 그래프, 수치 표
실험/제외_타인계정ChatGPT/ 분석에서 뺀 자료(삭제하지 않고 보관)
```

다시 계산하는 순서(Python 3, matplotlib, Pillow, numpy 가 필요하다).

```
cd 실험
python 01_예시효과/분석.py          # H1 다양성 점수 (분석결과.txt 출력과 같아야 한다)
python 02_다수의견프레이밍/집계.py  # H2 입장 분포 + Fisher
python 채점.py                      # H3·H4 자동 채점 -> H3H4_채점결과.txt
python 지표분석.py                  # H3·H4 응답 내용 지표 -> 지표분석결과.txt
python 그래프.py                   # H2, H3·H4 그림
python 표생성.py                   # 논문의 수치 표 -> 논문/수치표.md
```

짧은 확인 방법. 채점.py의 출력 중 ChatGPT 줄이 C 9/10, P 8/10, D 9/10 이고, 집계.py의 ChatGPT 줄이 X(n=10): 반대 6, 유보 3, 찬성 1 | Y(n=10): 반대 10 이면 원자료와 집계가 이 논문과 일치한다. 원자료의 개수는 raw_data 안에서 H2 모델별 20개, H3 모델별 20개(Q{n}_C, Q{n}_P), H4 모델별 10개(Q{n}_D), H1 모델별 10장이다.

새로 수집하려면. 각 설계.md의 프롬프트를 그대로 새 채팅(웹)이나 새 에이전트에 붙여 넣고, 응답 전문을 raw_data/<모델>/<이름>.md 로 저장한다(첫 줄에 모델·조건·시각·URL을 대괄호로 적는다). H1 이미지는 raw_data/<모델>/ 에 A_1.png 처럼 저장한다(ChatGPT 조건 B는 B_n_new.png). Claude H1은 SVG를 만들게 하고, 포스터모음.py 용 렌더링은 Chrome 헤드리스로 SVG를 PNG로 저장한다.

5-2. 사용한 도구와 공개 데이터

공개 데이터는 쓰지 않았다. 모든 자료는 직접 수집했다. 이미지 생성 API(pollinations.ai)는 유료화로 쓰지 못했다(2-5절). 웹 서비스는 ChatGPT(chatgpt.com), Gemini(gemini.google.com)를 본인 계정으로 사용했고, Claude는 코딩 도구의 서브에이전트를 썼다. 웹 서비스 조작은 브라우저 확장(Claude in Chrome)으로 프롬프트를 입력하고 응답을 읽었다.

5-3. 참고문헌

모든 문헌은 검색으로 실제 존재를 확인했다(확인 방법은 `과정기록/02_문헌조사.md`). 각 문헌 뒤의 "→"는 이 연구의 어느 부분과 연결되는지 한 줄이다. 실험·데이터 기반 연구에는 (실험)을 붙였다.

1. Bhattacharyya, A. (1943). On a measure of divergence between two statistical populations defined by their probability distributions. *Bulletin of the Calcutta Mathematical Society*, 35, 99–109. (원문은 열람하지 못하고 서지 정보만 확인) → H1의 색 분포 거리 $d = \sqrt{1-BC}$ 의 바탕이 된 Bhattacharyya 계수의 원전.
2. Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., et al. (2020). Language models are few-shot learners. *Advances in Neural Information Processing Systems*, 33. <https://arxiv.org/abs/2005.14165> → 프롬프트에 예시를 주는 방식의 출발점(H1의 배경).
3. Doshi, A. R., & Hauser, O. P. (2024). Generative AI enhances individual creativity but reduces the collective diversity of novel content. *Science Advances*, 10(28), eadn5290. <https://doi.org/10.1126/sciadv.adn5290> (실험) → AI의 도움을 받은 결과물이 서로 더 비슷해진다는 사람 대상 실험(H1).
4. Du, Y., Li, S., Torralba, A., Tenenbaum, J. B., & Mordatch, I. (2024). Improving factuality and reasoning in language models through multiagent debate. *Proceedings of the 41st International Conference on Machine Learning, PMLR 235*, 11733–11763. <https://arxiv.org/abs/2305.14325> (실험) → 여러 AI 인스턴스의 토론이 추론을 개선한다는 보고(H4).
5. Huang, J., Chen, X., Mishra, S., Zheng, H. S., Yu, A. W., Song, X., & Zhou, D. (2024). Large language models cannot self-correct reasoning yet. *The Twelfth International Conference on Learning Representations (ICLR 2024)*. <https://arxiv.org/abs/2310.01798> (실험) → 외부 피드백 없이는 스스로 고치기 어렵다는 보고(H4 토론 사례의 해석).
6. Jain, S., Lanchantin, J., Nickel, M., Ullrich, K., Wilson, A., & Watson-Daniels, J. (2025). *LLM output homogenization is task dependent*. arXiv:2509.21267. <https://arxiv.org/abs/2509.21267> (프리프린트) → 출력이 비슷해지는 정도가 과제에 따라 다르다는 논문(제목·저자 수준으로만 확인, H1에서 효과 크기가 모델·과제별로 다를 수 있다는 관점).
7. Sclar, M., Choi, Y., Tsvetkov, Y., & Suhr, A. (2024). Quantifying language models' sensitivity to spurious features in prompt design or: How I learned to start worrying about prompt formatting. *The Twelfth International Conference on Learning Representations (ICLR 2024)*. <https://arxiv.org/abs/2310.11324> (실험) → 프롬프트의 사소한 형식 차이가 결과를 크게 바꾼다는 보고(이 연구의 프롬프트 문구 한계).

8. Sharma, M., Tong, M., Korbak, T., Duvenaud, D., Aspell, A., Bowman, S. R., et al. (2024). Towards understanding sycophancy in language models. *The Twelfth International Conference on Learning Representations (ICLR 2024)*. <https://arxiv.org/abs/2310.13548> (실험) → AI가 사용자의 견해에 맞추는 경향(H2).
9. Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., et al. (2022). Chain-of-thought prompting elicits reasoning in large language models. *Advances in Neural Information Processing Systems*, 35. <https://arxiv.org/abs/2201.11903> (실험) → 풀이 과정을 쓰게 하는 구조적 신호가 추론을 바꾼다는 보고(H3·H4의 풀이 지시).
10. Weng, Z., Chen, G., & Wang, W. (2025). Do as we do, not as you think: The conformity of large language models. *The Thirteenth International Conference on Learning Representations (ICLR 2025)*. <https://arxiv.org/abs/2501.13381> (실험) → 다중 에이전트 상황에서의 동조(H2·H4).
11. Yun, L., An, C., Wang, Z., Peng, L., & Shang, J. (2025). *The price of format: Diversity collapse in LLMs*. arXiv:2505.18949. <https://arxiv.org/abs/2505.18949> (프리프린트, 실험) → 구조화된 프롬프트 형식이 출력 다양성을 줄인다는 보고(H1).
12. Zheng, M., Pei, J., Logeswaran, L., Lee, M., & Jurgens, D. (2024). When "A helpful assistant" is not really helpful: Personas in system prompts do not improve performances of large language models. *Findings of the Association for Computational Linguistics: EMNLP 2024*. <https://arxiv.org/abs/2311.10054> (실험) → 페르소나가 정확도를 높이지 않는다는 보고(H3).
13. Zhu, X., Zhang, C., Stafford, T., Collier, N., & Vlachos, A. (2025). Conformity in large language models. *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (ACL 2025, Main)*. <https://arxiv.org/abs/2410.12428> (실험) → LLM이 다수 의견에 동조하며 불확실할수록 더 그렇다는 보고(H2).

목록에서 뺀 것. Zheng et al.의 초기 버전(2023, 반대 결론), 2차 요약 사이트, EmotionPrompt 계열 (기각한 가설). 자세한 이유는 `과정기록/02_문헌조사.md` 6절에 있다.

5-4. AI에게 맡긴 일과 내가 판단한 일

표 21. AI와 사람의 역할 분담

구분	AI(Claude)가 한 일	내가(유지원) 판단하거나 정한 일
주제·가설	일반 후보 10개와 신박한 후보 8개를 제안, 가설 문장 초안	주제 선택(예시 효과, 다수의견 프레이밍, 페르소나, 토론 4개), "AI에게 감정이 있는 게 아니다"라는 전제 제시와 압박 문구 후보 기각, 여러 실험을 상위 가설 하나로 묶는 방향
설계	프롬프트·문제 세트·측정 지표·반증 조건 초안, 채점·집계 스크립트	최소 3개 AI 비교, 모든 AI와 같은 질문에서 시행 횟수를 같게 맞추는 것, 계정 분리 아이디어, 사진·그래프가 많은 논문
실행	프롬프트 입력, 블라인드 서브에이전트 실행, 응답 읽기·저장	본인 계정 연결·로그인, 타인 계정 사용 중단 지시, 한도·로그인 문제 대응
분석·해석	다양성·집계·채점·응답 지표 계산, 결과해석 초안	"정답밖에 없으면 논문이 의미 없다"는 지적, 표본이 작다는 지적, 결과를 어떻게 읽을지 판단
문헌	검색, 서지 정보 확인, 정리	어떤 문헌이 우리 가설과 연결되는지에 대한 최종 확인
논문	본문 초안 작성	논문의 취지와 시작·마무리 방향("AI는 말도 안 되게 똑똑할까!"로 시작해 "그럼에도 기하급수적으로 발전하고 있다"로 마무리)